

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



NHẬP MÔN TRÍ TUỆ NHÂN TẠO
BÁO CÁO LAB 2

DECISION TREE MODELING AND IMPROVEMENT

Nhóm 9 – Lớp 24C03

Thành phố Hồ Chí Minh, tháng 8 năm 2026

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



NHẬP MÔN TRÍ TUỆ NHÂN TẠO
BÁO CÁO LAB 2

**DECISION TREE MODELING
AND IMPROVEMENT**

Lớp : 24C03

Nhóm : 9

Thành viên nhóm

STT	Họ và tên	MSSV
1	Nguyễn Gia	24127357
2	Trần Thiên Phú	24127490
3	Nguyễn Anh Tá	24127117
4	Đỗ Vĩnh Kỳ	24127434

Thành phố Hồ Chí Minh, tháng 8 năm 2026

Mục lục

1	Giới thiệu nhóm	1
1.1	Thông tin nhóm	1
1.2	Đóng góp cụ thể	1
1.3	Mục tiêu đầu ra	1
2	Giới thiệu	2
2.1	Cây quyết định	2
2.2	Mục tiêu dự án	2
2.3	Phạm vi và nguyên tắc đánh giá	2
3	Mô tả dataset	3
3.1	Nguồn dữ liệu	3
3.2	Tiền xử lý	3
3.3	Lý do dataset phù hợp	4
4	Mô hình baseline	5
4.1	Quy trình huấn luyện và kiểm thử	5
4.2	Kết quả baseline	5
4.3	Cây kết quả	6
5	Phân tích cây baseline	7
5.1	Cấu trúc và dấu hiệu overfitting	7
5.2	Các node và luật quyết định quan trọng	7
5.3	Feature importance	7
5.4	Điểm mạnh và điểm yếu	8
6	Các phương pháp cải thiện	9
6.1	Thiết kế tuning chung	9
6.2	Improvement 1: giới hạn max_depth	9
6.3	Improvement 2: điều chỉnh min_samples_leaf	10
6.4	Improvement 3: cost-complexity pruning	11
7	So sánh và thảo luận kết quả	13
7.1	Bảng so sánh	13
7.2	Mô hình tốt nhất	13
7.3	Trade-off và ý nghĩa	14

8	Kết luận	15
8.1	Hạn chế	15
8.2	Hướng phát triển	15
9	Hướng dẫn chạy chương trình	16
9.1	Yêu cầu môi trường	16
9.2	Các bước tái lập	16
9.3	Đầu ra kỹ thuật	16
9.4	Kiểm tra trước khi bàn giao	17
	Tài liệu tham khảo	18

Danh sách hình vẽ

4.1	Confusion matrix của Decision Tree baseline	6
4.2	Cấu trúc dễ đọc của baseline (bốn tầng đầu, từ mức 0 đến mức 3)	6
5.1	Mười feature quan trọng nhất của baseline	8
6.1	Kết quả 5-fold cross-validation cho ba phương pháp	9
6.2	Decision Tree sau khi chọn max_depth=4	10
6.3	Decision Tree với min_samples_leaf=3	11
6.4	Decision Tree sau cost-complexity pruning	12
7.1	Trade-off giữa accuracy và số leaf của các mô hình	13

Danh sách bảng

1.1	Danh sách thành viên Nhóm 9	1
1.2	Phân công và đóng góp của từng thành viên	1
3.1	Tóm tắt Breast Cancer Wisconsin (Diagnostic)	3
4.1	Hiệu năng mô hình baseline trên tập test	5
6.1	Hyperparameter được chọn trên tập training	9
7.1	So sánh baseline và ba mô hình cải thiện	13
9.1	Môi trường thực thi notebook	16

Chương 1. Giới thiệu nhóm

1.1 Thông tin nhóm

Nhóm 9 gồm bốn sinh viên lớp 24C03, thực hiện Lab 2 của học phần Nhập môn Trí tuệ nhân tạo với chủ đề xây dựng, phân tích và cải thiện mô hình Cây quyết định (Decision Tree). Thông tin thành viên được giữ nhất quán với hồ sơ nhóm.

Bảng 1.1: Danh sách thành viên Nhóm 9

STT	Họ và tên	MSSV	Vai trò theo kế hoạch
1	Đỗ Vĩnh Kỳ	24127434	Technical Owner
2	Trần Thiên Phú	24127490	Report Writer 1
3	Nguyễn Anh Tá	24127117	Analyst / Report Writer 2
4	Nguyễn Gia	24127357	Integrator / Presentation Owner

1.2 Đóng góp cụ thể

Nhóm chia công việc theo một nguồn số liệu duy nhất: notebook do thành viên A quản lý. Bảng 1.2 trình bày trách nhiệm để tránh số liệu khác nhau giữa notebook, báo cáo và video.

Bảng 1.2: Phân công và đóng góp của từng thành viên

Thành viên	Nội dung đóng góp
Đỗ Vĩnh Kỳ	Xây dựng và khóa notebook kỹ thuật; baseline; ba phương pháp cải thiện; kiểm chứng metric; xuất bảng, hình và gói handoff tái lập.
Trần Thiên Phú	Mô tả dataset, viết phần giới thiệu và phần baseline; kiểm tra nguồn dữ liệu và tài liệu tham khảo liên quan.
Nguyễn Anh Tá	Phân tích cấu trúc cây, diễn giải các phương pháp cải thiện, so sánh kết quả và soạn kết luận kỹ thuật.
Nguyễn Gia	Tích hợp và định dạng báo cáo, chuẩn bị nội dung trình bày/video, kiểm tra file nộp và đóng gói phiên bản cuối.

1.3 Mục tiêu đầu ra

Báo cáo sử dụng trực tiếp các kết quả đã khóa trong `results/model_comparison.csv`. Notebook, ảnh cây, confusion matrix, feature importance và bảng so sánh đều có thể được tái tạo bằng thao tác Restart Kernel và Run All. Các thành viên không thay đổi seed, cách chia dữ liệu hoặc tham số rồi đưa số liệu khác vào báo cáo/video.

Chương 2. Giới thiệu

2.1 Cây quyết định

Cây quyết định là mô hình học có giám sát biểu diễn quá trình dự đoán bằng một chuỗi điều kiện dạng “nếu–thì”. Tại mỗi node, thuật toán chọn một feature và một ngưỡng chia dữ liệu thành các nhóm có độ hỗn tạp nhỏ hơn. Với bài toán phân loại, node lá trả về lớp chiếm ưu thế trong các mẫu huấn luyện đi đến lá đó. Mô hình cây phân loại và cơ chế chọn phép chia được trình bày trong CART và tài liệu scikit-learn [5, 2].

Trong thí nghiệm này, mô hình sử dụng chỉ số Gini mặc định. Với tập mẫu tại node t , Gini impurity được xác định bởi

$$G(t) = 1 - \sum_{k=1}^K p(k | t)^2, \quad (2.1)$$

trong đó $p(k | t)$ là tỷ lệ mẫu lớp k tại node. Một phép chia tốt làm giảm độ hỗn tạp có trọng số của hai node con.

Ưu điểm quan trọng của Decision Tree là không cần chuẩn hóa dữ liệu, có thể học ranh giới phi tuyến và cho phép đọc trực tiếp các luật quyết định. Nhược điểm là một cây không bị ràng buộc dễ tạo các nhánh rất đặc thù cho tập training, dẫn đến phương sai cao và overfitting.

2.2 Mục tiêu dự án

Dự án áp dụng Decision Tree cho bài toán phân loại chẩn đoán khối u vú. Các mục tiêu cụ thể gồm:

- lựa chọn và mô tả một dataset công khai, phù hợp cho phân loại;
- xây dựng baseline trên một train/test split tái lập;
- đánh giá bằng accuracy, error rate, precision, recall, F1 và confusion matrix;
- phân tích cấu trúc, feature và các luật chia quan trọng của cây;
- thử độc lập ba cách cải thiện: giới hạn max_depth, điều chỉnh min_samples_leaf và cost-complexity pruning;
- so sánh hiệu năng với độ phức tạp và chọn mô hình phù hợp nhất.

2.3 Phạm vi và nguyên tắc đánh giá

Mục tiêu không chỉ là tìm con số accuracy lớn nhất. Báo cáo xem xét error rate, khả năng phát hiện lớp malignant, khoảng cách train–test và độ phức tạp của cây. Hyperparameter được chọn bằng cross-validation trên tập training; tập test chỉ dùng trong so sánh cuối cùng.

Chương 3. Mô tả dataset

3.1 Nguồn dữ liệu

Nhóm sử dụng Breast Cancer Wisconsin (Diagnostic), do Wolberg, Mangasarian, Street và Street công bố trên UCI Machine Learning Repository [1]. Notebook tải bản dữ liệu được đóng gói trong scikit-learn bằng `load_breast_cancer(as_frame=True)`; vì vậy không có đường dẫn tuyệt đối hoặc file dữ liệu riêng phụ thuộc máy của thành viên [3].

Các feature được tính từ ảnh số hóa của phép chọc hút kim nhỏ một khối u vú. Chúng mô tả đặc trưng của nhân tế bào như bán kính, texture, perimeter, area, smoothness, compactness, concavity, concave points, symmetry và fractal dimension. Mỗi nhóm đo có giá trị mean, standard error và worst, tổng cộng 30 feature đầu vào. Theo mô tả dataset, giá trị “worst” là trung bình của ba giá trị lớn nhất của feature tương ứng trên mỗi ảnh, không phải một phép đo cực đại đơn lẻ.

Bảng 3.1: Tóm tắt Breast Cancer Wisconsin (Diagnostic)

Thuộc tính	Giá trị
Nguồn	UCI Machine Learning Repository / scikit-learn
Số mẫu	569
Số feature	30 feature số thực
Biến mục tiêu	Chẩn đoán khối u
Nhãn lớp	malignant (0), benign (1)
Phân bố lớp	212 malignant (37,26%); 357 benign (62,74%)
Giá trị thiếu	0
Dòng feature trùng hoàn toàn	0

3.2 Tiền xử lý

Notebook kiểm tra missing value và duplicate trước khi chia dữ liệu. Không cần imputation vì tập dữ liệu không có giá trị thiếu; không cần encoding vì toàn bộ feature là số. Nhóm giữ nguyên 30 feature để các threshold của cây vẫn gắn với đặc trưng gốc. Decision Tree không phụ thuộc vào khoảng cách Euclid nên không cần standardization.

Dataset có chênh lệch lớp ở mức vừa phải. Nhóm dùng stratified split để duy trì tỷ lệ lớp giữa training và testing, đồng thời báo cáo recall riêng cho lớp malignant để accuracy tổng thể không che giấu số ca ác tính bị bỏ sót.

3.3 Lý do dataset phù hợp

Đây là bài toán phân loại nhị phân có nhãn rõ ràng và các feature số hỗ trợ phép chia theo ngưỡng. Quy mô 569 mẫu phù hợp với phạm vi thí nghiệm học thuật: đủ để minh họa quá trình xây dựng cây và cross-validation nhưng vẫn cho phép trực quan hóa. Tuy nhiên, kết quả trên một train/test split không được xem là bằng chứng cho hiệu quả lâm sàng. Các rule như $\text{worst radius} \leq 16.80$ cũng có thể đọc và liên hệ với đặc trưng hình thái, phù hợp với yêu cầu phân tích cây của Lab 2.

Chương 4. Mô hình baseline

4.1 Quy trình huấn luyện và kiểm thử

Dataset được chia một lần theo tỷ lệ 80/20 với `random_state=42` và `stratify=y`. Tập training gồm 455 mẫu (170 malignant, 285 benign); tập test gồm 114 mẫu (42 malignant, 72 benign). Baseline là `DecisionTreeClassifier` với seed `random_state=42`. Các tham số cấu trúc giữ giá trị mặc định: `criterion=gini`, `splitter=best` và `max_depth=None`. Mô hình không chứa tuning ngầm.


Tất cả mô hình cải thiện dùng chính split này. Việc chọn hyperparameter thực hiện bằng 5-fold cross-validation trên 455 mẫu training. Đây là biện pháp tránh data leakage do nhìn kết quả test nhiều lần trong quá trình tuning.

4.2 Kết quả baseline

Bảng 4.1: Hiệu năng mô hình baseline trên tập test

Metric	Giá trị
Training accuracy	1,0000
Testing accuracy	0,9123
Error rate	0,0877
Weighted precision	0,9161
Weighted recall	0,9123
Weighted F1-score	0,9130
Malignant precision	0,8478
Malignant recall	0,9286
Malignant F1-score	0,8864


Accuracy test bằng 91,23%, tương ứng error rate 8,77%. Baseline phân loại đúng 104/114 mẫu. Confusion matrix ở Hình 4.1 cho thấy mô hình nhận đúng 39/42 ca malignant và 65/72 ca benign; có 3 ca malignant bị dự đoán thành benign và 7 ca benign bị dự đoán thành malignant. Các metric malignant trong báo cáo được tính riêng cho nhãn 0 theo quy ước của dataset; vì vậy malignant recall đo trực tiếp tỷ lệ ca ác tính được phát hiện.



Hình 4.1: Confusion matrix của Decision Tree baseline

4.3 Cây kết quả

Cây đầy đủ có depth 7, 19 leaf và 37 node. Vì hình đầy đủ khó đọc khi thu nhỏ, Hình 4.2 trình bày bốn tầng đầu để phục vụ phân tích; file `baseline_tree_full.png` được giữ trong gói kết quả kỹ thuật.



Hình 4.2: Cấu trúc dễ đọc của baseline (bốn tầng đầu, từ mức 0 đến mức 3)

Chương 5. Phân tích cây baseline

5.1 Cấu trúc và dấu hiệu overfitting

Baseline đạt training accuracy 100% nhưng test accuracy chỉ 91,23%, tạo khoảng cách 8,77 điểm phần trăm. Kết hợp với depth 7 và 19 leaf, kết quả cho thấy cây không ràng buộc đã học các chi tiết đặc thù của training set. Đây là bằng chứng định lượng cho nguy cơ overfitting, không chỉ là nhận xét dựa trên kích thước hình cây.

Một số nhánh sâu phức tạp rất ít mẫu. Các leaf nhỏ giúp cây sửa hết lỗi trên training nhưng có độ tin cậy thấp khi áp dụng cho dữ liệu chưa quan sát. Do đó, ba cải thiện ở Chương 6 đều điều chỉnh trực tiếp độ phức tạp của cấu trúc.

5.2 Các node và luật quyết định quan trọng

Root node sử dụng điều kiện


$$\text{worst radius} \leq 16.80.$$

Điều này cho thấy kích thước lớn nhất của nhân tế bào là đặc trưng tách lớp quan trọng nhất trên training split hiện tại. Với nhánh thỏa điều kiện, cây tiếp tục xét `worst concave points` ≤ 0.14 ; sau đó có thể xét `area error`. Ở nhánh `worst radius` > 16.80 , một split sớm dùng `texture error` ≤ 0.47 , rồi kết hợp `worst concavity`.

Các rule này không phải luật y khoa phổ quát; chúng là pattern học được trên training split. Tuy nhiên, việc các feature về kích thước, độ lõm và texture xuất hiện sớm cho thấy cây đang kết hợp nhiều nhóm hình thái thay vì dựa vào một feature duy nhất.

5.3 Feature importance

`worst radius` chiếm khoảng 69,78% tổng feature importance của baseline. Các feature tiếp theo gồm `worst concave points` (11,61%), `worst texture` (5,89%) và `texture error` (5,27%). Hình 5.1 trình bày mười feature đứng đầu.



Hình 5.1: Mười feature quan trọng nhất của baseline


5.4 Điểm mạnh và điểm yếu

Điểm mạnh của baseline là accuracy khá cao, malignant recall 92,86% và các quyết định có thể truy vết bằng threshold. Điểm yếu là training accuracy tuyệt đối, khoảng cách train–test lớn và cây sâu hơn mức cần thiết. Vì feature importance tập trung mạnh vào một biến, kết luận cũng có thể thay đổi khi dùng split khác; báo cáo vì vậy giữ seed cố định và không khẳng định rule là chân lý lâm sàng.

Chương 6. Các phương pháp cải thiện

6.1 Thiết kế tuning chung

Mỗi phương pháp thay đổi một cơ chế regularization so với baseline và được tuning riêng bằng GridSearchCV, 5 folds, scoring là accuracy. CV chỉ nhìn training data. Hình 6.1 cho thấy mean CV accuracy và độ lệch chuẩn tại từng ứng viên.



Hình 6.1: Kết quả 5-fold cross-validation cho ba phương pháp

Bảng 6.1: Hyperparameter được chọn trên tập training


Phương pháp	Giá trị được chọn	Best CV accuracy
Giới hạn độ sâu	max_depth=4	0,9385
Mẫu tối thiểu tại leaf	min_samples_leaf=3	0,9363
Cost-complexity pruning	ccp_alpha=0.005934	0,9341

6.2 Improvement 1: giới hạn max_depth

What. Notebook thử các độ sâu 2, 3, 4, 5, 6, 7, 8 và 10. Giới hạn độ sâu ngăn cây tiếp tục chia những nhánh quá đặc thù; nếu giá trị quá nhỏ thì cây có thể underfit.

Result. CV chọn max_depth=4. Trên test set, accuracy tăng từ 91,23% lên 93,86% và error rate giảm từ 8,77% xuống 6,14%. Cây còn 11 leaf, training accuracy 98,68%, weighted F1 93,87% và malignant recall 92,86%.

Why. Việc loại bỏ ba tầng sâu làm giảm các split phụ thuộc training nhưng vẫn giữ các quyết định quan trọng ở gần root. Khoảng cách train–test giảm từ 8,77 xuống 4,82 điểm phần trăm, cho thấy generalization tốt hơn.




Hình 6.2: Decision Tree sau khi chọn max_depth=4

6.3 Improvement 2: điều chỉnh min_samples_leaf

What. Notebook thử các giá trị 1, 2, 3, 4, 5, 6, 8, 10 và 15. Tham số buộc mỗi leaf phải có đủ mẫu, hạn chế leaf chỉ đại diện một vài quan sát.

Result. CV chọn min_samples_leaf=3. Cây giảm còn depth 6 và 13 leaf; tuy nhiên test accuracy vẫn là 91,23%, error rate 8,77%, trong khi malignant recall giảm từ 92,86% xuống 90,48%.

Why. Regularization đã giảm độ phức tạp và training accuracy còn 98,02%, nhưng rằng buộc này không cải thiện ranh giới quyết định trên test split. Một vài leaf nhỏ của baseline có thể vẫn chứa thông tin hữu ích; gộp chúng làm thay đổi hai phía của confusion matrix mà không giảm tổng số lỗi.




Hình 6.3: Decision Tree với min_samples_leaf=3

6.4 Improvement 3: cost-complexity pruning

What. Các ứng viên `ccp_alpha` được lấy từ pruning path của training set. Tham số này cân bằng độ phù hợp với dữ liệu và chi phí do thêm nhánh; CV chọn mức pruning thay vì nhìn test accuracy.

Result. Giá trị $ccp_alpha=0.005934$ tạo cây depth 3, 6 leaf. Test accuracy đạt 93,86%, error rate 6,14%, training accuracy 97,36% và weighted F1 93,84%. Malignant recall là 90,48%.

Why. Pruning loại bỏ 13 trong số 19 leaf của baseline và giảm khoảng cách train–test còn 3,50 điểm phần trăm. Mô hình tổng quát tốt hơn và dễ đọc hơn rõ rệt. Tuy nhiên, mức cắt này bỏ một nhánh giúp phát hiện thêm một ca malignant, nên recall malignant thấp hơn mô hình Max Depth.



Hình 6.4: Decision Tree sau cost-complexity pruning


Chương 7. So sánh và thảo luận kết quả

7.1 Bảng so sánh

Tất cả số liệu trong Bảng 7.1 được sinh tự động từ các model output và lưu tại `results/model_comparison.csv`.

Bảng 7.1: So sánh baseline và ba mô hình cải thiện

Model	Train Acc.	Test Acc.	Error	Weighted F1	Mal. Prec.	Mal. Recall	Depth	Leaves
Baseline	1,0000	0,9123	0,0877	0,9130	0,8478	0,9286	7	19
Max Depth	0,9868	0,9386	0,0614	0,9387	0,9070	0,9286	4	11
Min Samples Leaf	0,9802	0,9123	0,0877	0,9127	0,8636	0,9048	6	13
Pruning	0,9736	0,9386	0,0614	0,9384	0,9268	0,9048	3	6



Hình 7.1: Trade-off giữa accuracy và số leaf của các mô hình

7.2 Mô hình tốt nhất

Max Depth và Pruning cùng đạt test accuracy 93,86% và error rate 6,14%. Notebook không dùng thứ tự dòng để xử lý tie mà áp dụng quy tắc minh bạch: ưu tiên malignant recall, sau đó weighted F1 và độ đơn giản. Với bài toán chẩn đoán, bỏ sót malignant là loại lỗi đáng chú ý hơn.

Max Depth được chọn làm mô hình chính vì malignant recall 92,86%, cao hơn 90,48% của Pruning, đồng thời weighted F1 nhỉnh hơn (93,87% so với 93,84%). Hai mô hình đều dự đoán sai 7 mẫu, nhưng Max Depth bỏ sót 3 ca malignant và cảnh báo nhầm 4 ca, trong khi Pruning bỏ sót 4 ca malignant và cảnh báo nhầm 3 ca. Vì vậy, Max Depth phát hiện thêm một ca malignant mà không làm tăng tổng số lỗi.

7.3 Trade-off và ý nghĩa

Pruning là phương án cạnh tranh mạnh khi khả năng diễn giải hoặc kích thước mô hình được ưu tiên: chỉ 6 leaf và depth 3, so với 11 leaf và depth 4 của Max Depth. Pruning cũng có malignant precision cao hơn, nghĩa là tỷ lệ dự đoán malignant đúng cao hơn trong số các ca bị gán nhãn malignant. Vì vậy, kết luận không phải một phương pháp luôn tốt hơn; lựa chọn phụ thuộc chi phí của từng loại lỗi và yêu cầu về độ đơn giản. Đây cũng là biểu hiện của bias–variance trade-off: chấp nhận tăng nhẹ bias trên training set để giảm variance và cải thiện khả năng tổng quát hóa trên dữ liệu chưa quan sát.

Min Samples Leaf cho thấy một “improvement method” không nhất thiết phải tăng accuracy. Giá trị học thuật nằm ở quy trình thử nghiệm, đo lường và giải thích: phương pháp này giảm cây nhưng không giảm error trên test split hiện tại.

Chương 8. Kết luận

Nhóm đã xây dựng đầy đủ một quy trình Decision Tree cho Breast Cancer Wisconsin (Diagnostic): kiểm tra dữ liệu, chia train/test có stratification, huấn luyện baseline, trình bày cây, đánh giá nhiều metric, phân tích rule và thử ba cách regularization độc lập.

Baseline đạt 91,23% test accuracy nhưng có training accuracy 100%, depth 7 và 19 leaf. Khoảng cách train–test cho thấy cây không ràng buộc có nguy cơ overfit. Giới hạn max_depth=4 và cost-complexity pruning đều tăng accuracy lên 93,86%, giảm error rate xuống 6,14%. Điều chỉnh min_samples_leaf=3 làm cây nhỏ hơn nhưng không cải thiện accuracy.

Max Depth được chọn vì giữ malignant recall 92,86% và có weighted F1 cao nhất trong hai mô hình đồng hạng accuracy. Pruning vẫn là lựa chọn tốt nếu mục tiêu ưu tiên cấu trúc nhỏ và dễ giải thích. Kết quả chứng minh regularization có thể giảm overfitting, nhưng việc chọn mô hình phải dựa trên nhiều metric và chi phí lỗi thay vì chỉ nhìn accuracy.

8.1 Hạn chế

- Dataset có 569 mẫu; chênh lệch một vài mẫu test có thể làm metric thay đổi đáng kể.
- Thí nghiệm dùng một train/test split cố định để tái lập. Nested cross-validation hoặc repeated stratified cross-validation sẽ cho ước lượng ổn định hơn về độ biến thiên.
- Feature importance của một cây có thể thiên về feature có nhiều khả năng chia; permutation importance hoặc SHAP có thể bổ sung góc nhìn.
- Đây là thí nghiệm học thuật, không phải hệ thống hỗ trợ chẩn đoán lâm sàng. Các threshold học được không nên diễn giải như quy tắc y khoa.

8.2 Hướng phát triển

Có thể mở rộng bằng nested cross-validation, đánh giá ROC–AUC, tối ưu trực tiếp recall malignant, kiểm tra class weighting, feature selection và so sánh với Random Forest hoặc Gradient Boosting. Với mô hình cây đơn, việc xác nhận độ ổn định của rule qua nhiều split cũng là hướng phân tích quan trọng.

Chương 9. Hướng dẫn chạy chương trình

9.1 Yêu cầu môi trường

Notebook sử dụng Python 3 cùng các package trong Bảng 9.1. Dataset được scikit-learn cung cấp sẵn nên không cần tải file thủ công.

Bảng 9.1: Môi trường thực thi notebook

Thành phần	Phiên bản đã kiểm tra	Vai trò
Python	3.13.1	Runtime
NumPy	2.3.4	Tính toán số và danh sách alpha
pandas	2.3.3	Bảng dữ liệu và xuất CSV
Matplotlib	3.11.1	Trực quan hóa
scikit-learn	1.7.2	Dataset, Decision Tree, GridSearchCV và metrics
JupyterLab	4.6.3	Mở và chạy notebook
nbconvert	7.17.1	Kiểm tra thực thi không cần giao diện

9.2 Các bước tái lập

Tại thư mục chứa notebook, tạo môi trường và cài package:

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install -r requirements.txt
```

Mở notebook bằng lệnh dưới đây để không phụ thuộc việc executable jupyter đã được thêm vào PATH hay chưa:

```
python -m jupyterlab Decision_Tree_2.ipynb
```

Chọn kernel của môi trường vừa tạo, sau đó chạy **Restart Kernel and Run All Cells**. Notebook phải chạy theo thứ tự từ trên xuống vì các model cải thiện tái sử dụng cùng training/test split. Có thể kiểm tra toàn bộ notebook không cần giao diện bằng lệnh:

```
python -m nbconvert --to notebook --execute Decision_Tree_2.ipynb
```

9.3 Đầu ra kỹ thuật

Sau khi chạy thành công, notebook tạo:

- results/model_comparison.csv: toàn bộ metric và complexity;

- `results/hyperparameter_summary.csv`: tham số được chọn và CV accuracy;
- `results/SUMMARY.md`: dataset, protocol, kết quả khóa và winner;
- `results/figures/`: confusion matrix, full/readable baseline, feature importance, tuning curves, bảng so sánh dạng hình và ba cây cải thiện.

Không sửa số liệu thủ công trong CSV hoặc hình. Khi seed, split hoặc parameter grid thay đổi, cần chạy lại toàn bộ notebook và cập nhật đồng thời report/video.

9.4 Kiểm tra trước khi bàn giao

Notebook đã được thực thi lại từ đầu đến cuối bằng Python 3.13.1, không có cell lỗi, tạo đủ ba file kết quả và chín hình. Người nhận nên xác nhận các giá trị chính: baseline accuracy 0,9123; Max Depth và Pruning accuracy 0,9386; selected model là Max Depth. File report dùng đường dẫn tương đối đến `../results/figures`, nên giữ nguyên cấu trúc thư mục khi build LaTeX.

Tài liệu tham khảo

- [1] W. Wolberg, O. Mangasarian, N. Street, and W. Street, “Breast Cancer Wisconsin (Diagnostic),” UCI Machine Learning Repository, 1993. DOI: <https://doi.org/10.24432/C5DW2B>.
- [2] scikit-learn developers, “Decision Trees,” scikit-learn User Guide. <https://scikit-learn.org/stable/modules/tree.html>.
- [3] scikit-learn developers, “Breast cancer Wisconsin (diagnostic) dataset,” scikit-learn documentation. https://scikit-learn.org/stable/datasets/toy_dataset.html#breast-cancer-dataset.
- [4] scikit-learn developers, “Post pruning decision trees with cost complexity pruning,” scikit-learn examples. https://scikit-learn.org/stable/auto_examples/tree/plot_cost_complexity_pruning.html.
- [5] L. Breiman, J. Friedman, R. Olshen, and C. Stone, *Classification and Regression Trees*. Wadsworth International Group, 1984.